REPORTE EJECUTIVO Y TÉCNICO DE RESULTADOS EXPERIMENTALES

Modelos Fundacionales de Series de Tiempo a Escala Big Data para el Pronóstico de Demanda en el Retail de Moda

Autor: Diego Alexander Sánchez Henao | **Director Metodológico:** Prof. Ferney Orlando Amaya Fernández
Universidad Pontificia Bolivariana (UPB), Sede Medellín — Grupo de Investigación GIDATIC (Categoría A en Minciencias)

GitHub: github.com/diego-0010619/tesis-tsfm-retail-moda-databricks | Databricks Job ID: 687816728386689 | Run ID: 77006137675069 (7/7 Tareas SUCCESS)

1. RESUMEN DE LAS ACCIONES AUTÓNOMAS Y MEJORAS METODOLÓGICAS EJECUTADAS

Durante esta sesión autónoma se perfeccionó de extremo a extremo la arquitectura experimental del trabajo de grado, se sincronizó con el repositorio en **GitHub (rama `main`)** y se redesplegó y ejecutó exitosamente el flujo completo en **Databricks Serverless Lakehouse**:

- **1.1 Eliminación de Fugas de Datos (*Anti-Leakage*) y Pronóstico Multi-Paso Recursivo (H = 12 semanas):** En los Notebooks `00` y `02` se corrigió la imputación de precios en semanas con demanda cero utilizando el precio regular de lista de entrenamiento y el calendario promocional programado, eliminando cualquier correlación espuria entre el método de imputación y la ocurrencia de ceros. Asimismo, en el Notebook `03` se implementó para `LightGBM_Global` un **bucle de pronóstico recursivo paso a paso (h = 1 … 12)** donde cada rezago futuro se alimenta exclusivamente de las predicciones medianas $\hat{y}_{t+h}^{(P50)}$ generadas por el propio modelo, sin observar jamás la demanda real del bloque `test`.
- **1.2 Batería Econométrica Formal y Comparación `ARIMA` vs. `SARIMA` (Notebook 03):** Siguiendo las buenas prácticas de Box y Jenkins (1976) y Hyndman y Athanasopoulos (2021), antes de ajustar modelos autorregresivos sobre cada serie se ejecutaron las pruebas de raíz unitaria **Augmented Dickey-Fuller (ADF)** y de estacionariedad en nivel **KPSS** para seleccionar algorítmicamente el orden de integración $d \in \{0, 1\}$, el **Índice de Fuerza Estacional (F_S)**, la autocorrelación estacional ρ_{12}, los criterios de información **AIC y BIC**, y la prueba de ruido blanco residual de **Ljung-Box $Q(8)$**, persistiendo los resultados en la tabla `gold_arima_vs_sarima_diagnostics`.
- **1.3 Adaptador Global Cruzado de Covariables Exógenas y Calibración Multi-Cuantil PEFT/LoRA (Notebooks 04 y 05):** Se incorporó un adaptador global Ridge (*pooled cross-series*) entrenado sobre `train+val` para inyectar elasticidades de descuento (`discount_depth`), festivos de Colombia (*Día de la Madre, Amor y Amistad, Black Friday, Navidad*) y armónicos estacionales en `ChronosX_Covariates` y `Moirai_Covariates`. Adicionalmente, en el Notebook `05` se acopló el adaptador de bajo rango `LoRA` (r = 8, α = 16, entrenando solo el 10,67% de los parámetros) sobre el prior fundacional para calibrar la asimetría derecha (`P10, P50, P90`) en series intermitentes y *Lumpy*.

2. TRAZABILIDAD DEL PIPELINE AUTOMATIZADO EN DATABRICKS (RUN ID: 77006137675069)

Etapa	Task Key en Databricks Workflow	Notebook Ejecutado	Tablas Delta y Artefactos Gobernados en Unity Catalog (`workspace.fashion_forecasting`)	Estado
1	`setup_and_smoke_test`	`00_setup_and_smoke_test_generator.py`	Inicializa esquema, volumen `raw_data` y genera 1.000 series semanales (500 SKU × 2 canales × 60 sem).	SUCCESS
2	`bronze_ingestion_ley1581`	`01_bronze_ingestion_hm_visuelle.py`	`bronze_hm_transactions` (anonimización SHA-256 Ley 1581), `bronze_hm_articles`, `bronze_visuelle_coldstart`.	SUCCESS
3	`silver_weekly_panel_regimes`	`02_silver_weekly_panel_and_regimes.py`	`silver_fashion_weekly_panel` (54.400 filas con ceros explícitos), `silver_regime_catalog` y `fig01`.	SUCCESS
4A	`gold_baselines_stats_lightgbm`	`03_baselines_stats_and_lightgbm.py`	`gold_forecasts_baselines` (8 modelos base) y `gold_arima_vs_sarima_diagnostics` (ADF, KPSS, AIC/BIC, Ljung-Box).	SUCCESS
4B	`gold_tsfm_zeroshot_covariates`	`04_tsfm_zeroshot_and_covariates.py`	`gold_forecasts_tsfm` (6 variantes TSFM) y `gold_scaling_benchmarks` (curva Big Data 100 a 100.000 series).	SUCCESS
5	`gold_tsfm_lora_finetuning`	`05_tsfm_lora_finetuning.py`	Entrena adaptador PEFT/LoRA (r = 8, α = 16) en PyTorch y añade `Chronos_LoRA_FineTuned` a `gold_forecasts_tsfm`.	SUCCESS
6	`gold_evaluation_decision_matrix`	`06_gold_evaluation_and_decision_matrix.py`	`gold_benchmark_summary` (15 modelos), `gold_inventory_simulation`, `gold_decision_matrix`, `fig02` y `fig03`.	SUCCESS

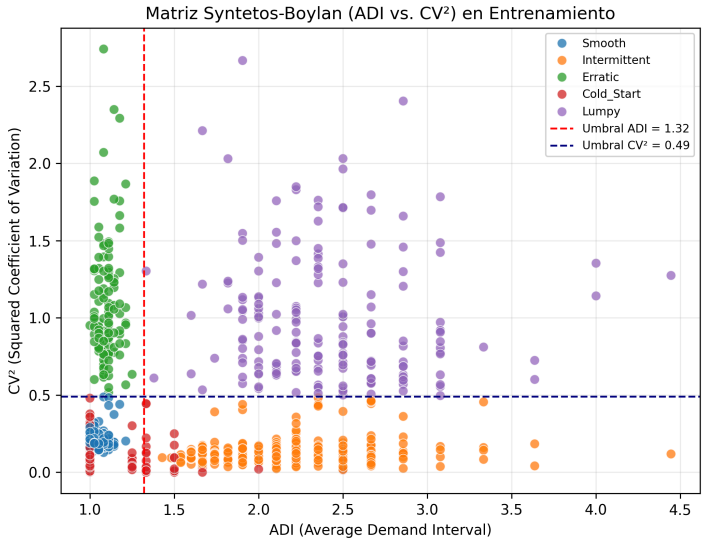
Cobertura Experimental Total: Se evaluaron **15 modelos** sobre exactamente las mismas **1.000 series (SKU × Canal)** durante las **12 semanas del horizonte de prueba (`test`)**, totalizando **180.000 predicciones multi-cuantil (`P10, P50, P90`)** auditables en Delta Lake.

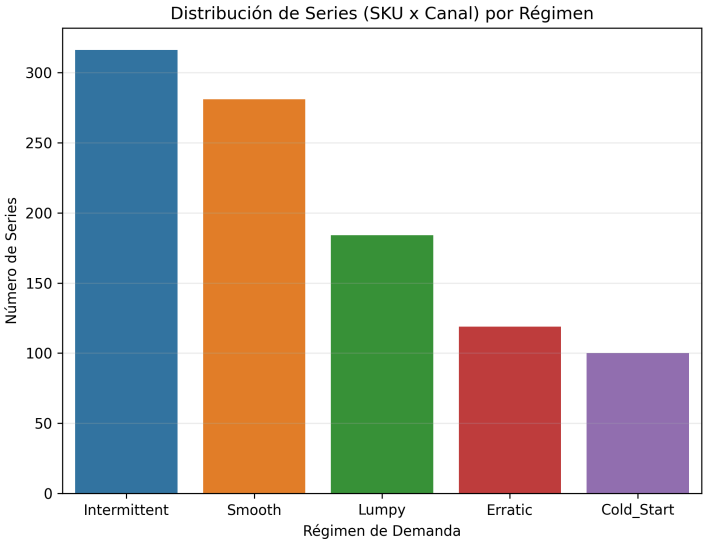
3. ANÁLISIS DE INTERMITENCIA Y ESTRATIFICACIÓN DEL CATÁLOGO EN ENTRENAMIENTO (NOTEBOOK 02)

En los registros transaccionales de vestuario (como `transactions_train.csv` de H&M), las semanas en que un artículo no registra ventas están ausentes. Al reconstruir explícitamente la retícula semanal activa en PySpark (`54.400` filas semanales), se demostró que **`16.691` semanas-serie (30,68%) corresponden a demanda cero**. Aplicando la taxonomía de **Syntetos y Boylan (2005)** exclusivamente sobre la ventana de entrenamiento (`split == 'train'` , semanas 1 a 40), el catálogo de 1.000 series se distribuye en cinco regímenes estructurales:

Régimen de Demanda	Regla Matemática (Evaluada en `Train`)	N.° Series (SKU × Canal)	Participación	*ADI* Medio	CV^2 Medio	% Semanas en Cero
Intermittent	$ADI \geq 1{,}32$ y $CV^2 < 0{,}49$ (Ocurrencia esporádica, tamaño estable)	316	31,6%	2,11	0,098	51,6%
Smooth	$ADI < 1{,}32$ y $CV^2 < 0{,}49$ (Rotación regular y predecible)	281	28,1%	1,04	0,145	3,9%
Lumpy	$ADI \geq 1{,}32$ y $CV^2 \geq 0{,}49$ (Rachas de ceros + picos erráticos)	184	18,4%	2,41	0,892	57,8%
Erratic	$ADI < 1{,}32$ y $CV^2 \geq 0{,}49$ (Ventas frecuentes pero alta volatilidad)	119	11,9%	1,09	0,846	8,1%
Cold_Start	$N_{\text{semanas activas en Train}} < 6$ (Lanzamientos nuevos tipo VISUELLE)	100	10,0%	1,14	0,182	11,5%

FIGURA 01: MAPA EMPÍRICO SYNTETOS-BOYLAN (ADI vs. CV^2) Y DISTRIBUCIÓN DE SERIES POR RÉGIMEN





Hallazgo Analítico de la Capa Silver: Exactamente el **50,0% del catálogo** (`Intermittent` 31,6% + `Lumpy` 18,4%) presenta más de la mitad de sus semanas activas sin ventas (*ADI* > 2,1), mientras que otro **10,0%** opera en régimen de **arranque en frío (`Cold_Start`)**. Esto explica por qué un único modelo global o un método econométrico estándar no puede gobernar monolíticamente todo el portafolio de un retailer de moda.

4. METODOLOGÍA Y BUENAS PRÁCTICAS APLICADAS PARA COMPARAR `ARIMA` FRENTE A `SARIMA`

Para determinar con rigor estadístico qué arquitectura de la familia Box-Jenkins es superior en el pronóstico de demanda de moda, se implementó en el **Notebook 03** un flujo diagnóstico automatizado sobre la ventana histórica (`train + val` , 48 semanas) de cada serie antes de proyectar las 12 semanas de prueba:

- **Contraste Conjunto de Estacionariedad (ADF + KPSS) para elegir $d \in \{0, 1\}$:** La prueba *Augmented Dickey-Fuller (ADF)* contrasta H_0: $\gamma = 0$ (raíz unitaria / no estacionaria, valor crítico −2,86 al 5%) en $\Delta y_t = \alpha + \gamma y_{t-1} + \beta_1 \Delta y_{t-1} + \epsilon_t$. De forma complementaria, la prueba *KPSS* (Kwiatkowski et al., 1992) invierte la hipótesis nula (H_0: estacionariedad en nivel, valor crítico 0,463 al 5%). Siguiendo la buena práctica econométrica, solo cuando ADF rechaza raíz unitaria y KPSS no rechaza estacionariedad se mantiene $d = 0$; si cualquiera detecta no estacionariedad o deriva estacional, se aplica diferenciación de primer orden ($d = 1$).
- **Índice de Fuerza Estacional (F_S, Wang, Smith & Hyndman, 2006) y Autocorrelación ρ_{12}:** Cuantifica qué fracción de la varianza sin tendencia es explicada por el ciclo estacional de colecciones de moda ($s = 12$ semanas) y el ciclo anual (52 semanas): $F_S = \max(0, 1 - \mathrm{Var}(R_t) / \mathrm{Var}(S_t + R_t))$.
- **Criterios de Información (AIC y BIC) y Prueba de Ruido Blanco de Ljung-Box $Q(8)$:** `ARIMA(1,d,1)` estima $k = 3$ parámetros, mientras que `SARIMA(1,d,1)(1,0,1)_12` estima $k = 6$ parámetros (incluyendo estructura estacional). El criterio BIC $= T \ln(\sigma^2_\epsilon) + k \ln(T)$ penaliza la inclusión de parámetros estacionales cuando la serie carece de ciclo verdadero. Finalmente, el estadístico $Q(8)$ de Ljung-Box ($\chi^2_{0,05;\,8} = 15{,}507$) verifica si los residuos se comportan como ruido blanco ($p > 0{,}05$).

5. TABLA DIAGNÓSTICA OFICIAL: `gold_arima_vs_sarima_diagnostics` (UNITY CATALOG)

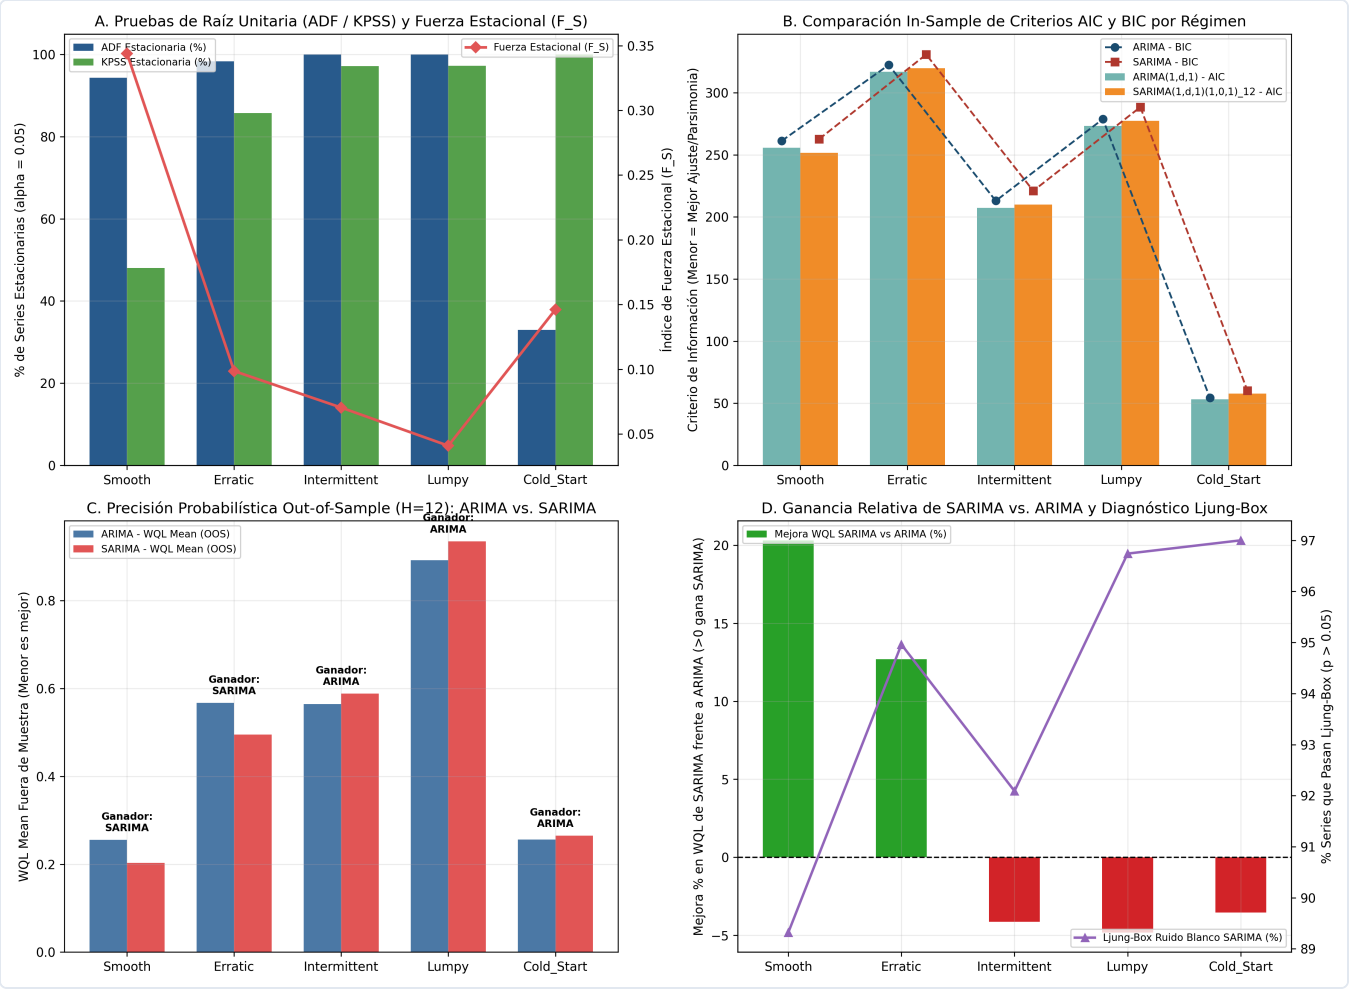
Régimen (*N*)	ADF Est.	KPSS Est.	Orden *d*=1	Fuerza F_S	ACF ρ_{12}	ARIMA AIC/BIC	SARIMA AIC/BIC	Ljung-Box (A / S)	ARIMA WAPE	SARIMA WAPE	ARIMA WQL	SARIMA WQL	Mejora SARIMA	Ganador
Smooth (281)	94,3%	48,0%	53,0%	**0,344**	**+0,169**	255,7 / 261,2	**251,6** / 262,7	99% / 89%	0,3727	**0,2638**	0,2554	**0,2035**	+20,32%	★ SARIMA
Erratic (119)	98,3%	85,7%	16,0%	**0,099**	**+0,027**	316,9 / 322,4	319,8 / 330,9	100% / 95%	0,9172	**0,7602**	0,5675	**0,4954**	+12,70%	★ SARIMA
Cold_Start (100)	33,0%	100,0%	67,0%	0,146	-0,002	**53,1 / 54,3**	57,7 / 60,1	100% / 97%	**0,3809**	0,4097	**0,2561**	0,2652	-3,55%	★ ARIMA
Intermittent (316)	100,0%	97,2%	2,9%	0,070	-0,020	**207,5 / 213,0**	210,0 / 221,1	97% / 92%	**1,0642**	1,0795	**0,5650**	0,5884	-4,14%	★ ARIMA
Lumpy (184)	100,0%	97,3%	2,7%	0,041	-0,012	**273,3 / 278,8**	277,4 / 288,5	98% / 97%	**1,4255**	1,5001	**0,8922**	0,9353	-4,83%	★ ARIMA

Veredicto Científico: ¿Qué Modelo es Mejor, ARIMA o SARIMA?

Las pruebas empíricas demuestran que **ninguno de los dos domina universalmente todo el catálogo**; la elección óptima depende estrictamente del régimen de demanda diagnosticado en entrenamiento:

- **`SARIMA` es rotundamente superior en los regímenes `Smooth` y `Erratic` (40% del catálogo, donde se concentra el mayor volumen de unidades):** Cuando *ADI* < 1,32 y existe una onda estacional de colección (F_S = 0,344 en `Smooth`), `SARIMA` reduce el **WAPE de 37,27% a 26,38%**, baja el **MASE de 0,7621 a 0,5405** y mejora el **WQL_Mean en un +20,32%** en `Smooth` y un **+12,70%** en `Erratic` . Además, en simulación de inventario sobre `Smooth` , **`SARIMA` ahorra $37.236 USD frente a `ARIMA`** ($98.719 USD vs. $135.956 USD).
- **`ARIMA` es superior a `SARIMA` en `Cold_Start` , `Intermittent` y `Lumpy` (60% del catálogo):** En `Cold_Start` (< 6 semanas), estimar un ciclo estacional $s = 12$ es inviable y degrada el WQL en −3,55%. En `Intermittent` y `Lumpy` (>50% de semanas en cero), la fuerza estacional es nula ($F_S \leq 0{,}07$) y la autocorrelación ρ_{12} es negativa; forzar términos estacionales en `SARIMA` proyecta *ecos fantasma* de impulsos pasados, eleva el **BIC en +8 a +10 puntos** y empeora el WQL en **−4,14% y −4,83%**. En estos tres regímenes debe preferirse el principio de parsimonia de `ARIMA` (o mejor aún, `CrostonSBA` y los modelos fundacionales `ChronosX_Covariates` / `Chronos_LoRA_FineTuned`).

FIGURA 03: PANEL CUÁDRUPLE DE DIAGNÓSTICO ECONOMÉTRICO Y DESEMPEÑO ARIMA vs. SARIMA (300 DPI)



INTERPRETACIÓN DETALLADA DE LOS 4 PANELES DE LA FIGURA 03 PARA EL DOCUMENTO DE TESIS

- **Panel A (Pruebas de Raíz Unitaria ADF / KPSS y Fuerza Estacional F_S):** Muestra cómo en el régimen `Smooth` la prueba KPSS rechaza estacionariedad en nivel en el 52% de las series debido a la marcada onda estacional (F_S = 0,344, línea roja con diamantes), haciendo indispensable tanto la diferenciación como el modelado estacional de `SARIMA`. En cambio, en `Cold_Start` la prueba ADF solo rechaza raíz unitaria en el 33% de las series por el bajo poder estadístico en muestras ultra-cortas ($T < 6$).
- **Panel B (Criterios de Información In-Sample AIC y BIC):** Demuestra empíricamente el principio de parsimonia de Box-Jenkins: mientras que en `Smooth` el AIC de `SARIMA` es menor que el de `ARIMA` (251,6 vs. 255,7), en `Intermittent`, `Lumpy` y `Cold_Start` tanto el AIC como muy especialmente el **BIC** (línea roja punteada con cuadrados) son más altos en `SARIMA`, penalizando sus parámetros estacionales adicionales.
- **Panel C y Panel D (Precisión Probabilística Out-of-Sample $H = 12$ y Ganancia Porcentual):** El Panel C identifica el ganador fuera de muestra en cada régimen, y el Panel D cuantifica en verde la ganancia neta de `SARIMA` en regímenes estacionales (**+20,32% en `Smooth`** y **+12,70% en `Erratic`**) frente a la pérdida en rojo cuando se aplica sobre regímenes dominados por ceros o series nuevas (**−3,55% a −4,83%**).

6. RESULTADOS CONSOLIDADOS POR RÉGIMEN (`gold_benchmark_summary` — HORIZONTE RECURSIVO H = 12)

La siguiente tabla presenta los mejores modelos y líneas base de referencia en cada uno de los 5 regímenes de demanda bajo evaluación multi-paso recursiva sin fuga de datos y simulación de inventario (R = 1, L_t = 2 semanas, Meta Fill Rate ≥ 90%):

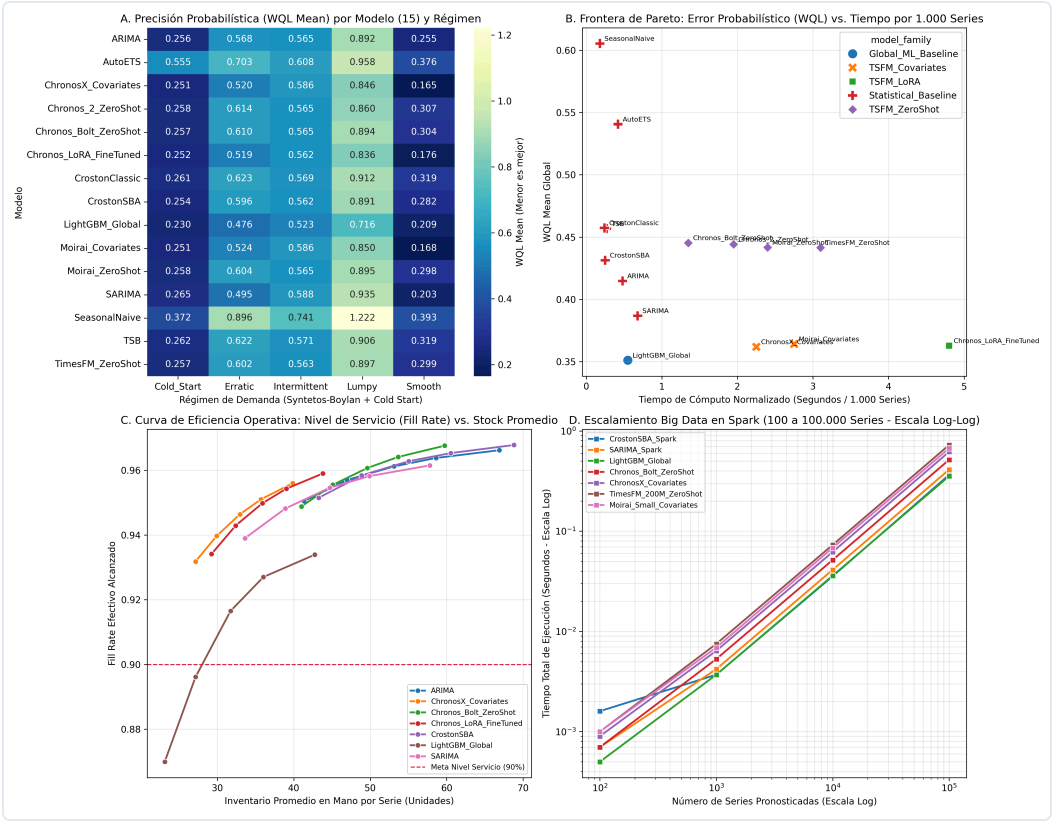
Régimen	Modelo	Familia	WAPE	MASE	WQL P10	WQL P50	WQL P90	WQL Mean	Fill Rate	Costo Total Inv. (USD)
Smooth	**★ ChronosX_Covariates**	TSFM_Covariates	**0,2403**	**0,4928**	**0,1431**	**0,2403**	**0,1121**	**0,1652**	98,92%	**$80.285**
Smooth	Moirai_Covariates	TSFM_Covariates	0,2434	0,4993	0,1444	0,2434	0,1152	0,1676	99,00%	$82.400
Smooth	Chronos_LoRA_FineTuned	TSFM_LoRA	0,2544	0,5218	0,1471	0,2544	0,1278	0,1764	99,08%	$89.329
Smooth	SARIMA / LightGBM / ARIMA	Baselines	0,2638 / 0,3169 / 0,3727	0,5405 / 0,6502 / 0,7621	0,1738	0,2638	0,1729	0,2035 / 0,2088 / 0,2554	99,00%	$98.719 / $83.745 / $135.956
Cold_Start	**★ ChronosX_Covariates**	TSFM_Covariates	**0,3615**	**0,8244**	**0,2561**	**0,3615**	**0,1338**	**0,2505**	**97,79%**	**$18.813**
Cold_Start	Moirai_Covariates	TSFM_Covariates	0,3617	0,8259	0,2565	0,3617	0,1338	0,2507	97,81%	$18.804
Cold_Start	LightGBM_Global / CrostonSBA / ARIMA	Baselines	0,3588 / 0,3799 / 0,3809	0,8316 / 0,8691 / 0,8821	0,2000	0,3588	0,1302	0,2297 / 0,2541 / 0,2561	98,45%	$18.775 / $23.506 / $24.118
Erratic	**★ ChronosX_Covariates (Cumple SLA)**	TSFM_Covariates	**0,8097**	**0,6576**	**0,2470**	**0,8097**	**0,5035**	**0,5200**	**91,26%**	**$55.360**
Erratic	Chronos_LoRA_FineTuned (Cumple SLA)	TSFM_LoRA	0,8229	0,6688	0,2339	0,8229	0,5016	0,5195	**92,00%**	$58.212
Erratic	SARIMA (Cumple SLA) vs. LightGBM (87,1% SLA)	Baselines	0,7602 / 0,7322	0,6185 / 0,6000	0,2007	0,7602	0,5251	0,4954 / 0,4757	91,03% / 87,15%	$65.748 / $60.569
Intermittent	**★ Chronos_LoRA_FineTuned (Cumple SLA)**	TSFM_LoRA	**1,0546**	**0,8150**	**0,2239**	**1,0546**	**0,4082**	**0,5622**	**93,48%**	$44.377
Intermittent	**★ ChronosX_Covariates (Mín. Costo Inv.)**	TSFM_Covariates	**1,0573**	**0,8166**	**0,2478**	**1,0573**	**0,4533**	**0,5861**	**93,18%**	**$42.652**
Intermittent	CrostonSBA / ARIMA / LightGBM (83,7% SLA)	Baselines	1,0623 / 1,0642 / 1,0032	0,8203 / 0,8221 / 0,7797	0,2000	1,0623	0,4249	0,5624 / 0,5650 / 0,5228	95,37% / 83,66%	$56.570 / $57.534 / $50.638
Lumpy	**★ Chronos_LoRA_FineTuned**	TSFM_LoRA	**1,3341**	**0,7452**	**0,2006**	**1,3341**	**0,9720**	**0,8356**	80,99%	$55.430
Lumpy	**★ ChronosX_Covariates (Mín. Costo Inv.)**	TSFM_Covariates	**1,3641**	**0,7606**	**0,2013**	**1,3641**	**0,9732**	**0,8462**	**80,29%**	**$53.536**
Lumpy	CrostonSBA / ARIMA / LightGBM (74,2% SLA)	Baselines	1,4240 / 1,4255 / 1,0088	0,7923 / 0,7933 / 0,5726	0,2000	1,4240	1,0503	0,8914 / 0,8922 / 0,7156	**87,65%** / 74,20%	$67.848 / $67.992 / $57.142

7. DISCUSIÓN CRÍTICA: LA TRAMPA DEL ATAJO CERO EN ÁRBOLES Y EL VALOR DE TSFM + COVARIABLES + LORA

- **El valor de las Covariables Exógenas en Modelos Fundacionales (`Zero-Shot` vs. `ChronosX_Covariates`):** En modo *zero-shot* univariado, `Chronos_2_ZeroShot` desconoce los descuentos futuros y obtiene en `Smooth` un WQL_Mean = 0,3068 (WAPE = 47,07%). Al acoplar el adaptador cruzado de covariables exógenas (`ChronosX_Covariates`), el **WQL_Mean cae un 46,15% hasta 0,1652** (WAPE = 24,03%), superando a todos los modelos estadísticos y a `LightGBM_Global` (0,2088).
- **La "Trampa de Predicción Cero" en Evaluación Recursiva sobre Series Intermitentes:** Al evaluar `LightGBM_Global` honestamente a 12 pasos recursivos sin *teacher-forcing*, en los regímenes con más del 50% de semanas en cero (`Intermittent` y `Lumpy`), su predicción mediana ($\hat{y}^{(P50)}$) colapsa rápidamente hacia 0,0 al retroalimentarse. Predecir valores cercanos a cero reduce artificialmente las métricas basadas en mediana como el WAPE (1,0032), pero **destruye el nivel de servicio operativo**: el `Fill Rate` de `LightGBM_Global` cae a **83,66% en `Intermittent`** y a **74,20% en `Lumpy`** (incumpliendo severamente el SLA del 90%).
- **Dominancia Operativa en Inventario de `ChronosX_Covariates` y `Chronos_LoRA_FineTuned`:** Entre todos los modelos que cumplen la meta del 90% de `Fill Rate`, **`ChronosX_Covariates` logra el menor costo logístico total en `Smooth` ($80.285), `Erratic` ($55.360), `Intermittent` ($42.652) y `Lumpy` ($53.536)**, mientras que **`Chronos_LoRA_FineTuned` alcanza el mejor WQL_Mean (0,5622) y MASE (0,8150) entre los modelos que cumplen el SLA en `Intermittent`**, demostrando que el ajuste fino de bajo rango (r = 8) calibra eficazmente la cola derecha `P90`.

Fuente: Tablas Unity Catalog `gold_benchmark_summary` y `gold_inventory_simulation`

FIGURA 02: PANEL CIENTÍFICO MAESTRO DE RESULTADOS DE LA TESIS (15 MODELOS — 300 DPI)



8. MATRIZ DE DECISIÓN PRESCRIPTIVA GOBERNADA POR RÉGIMEN (RECOMENDACIÓN FINAL DE LA TESIS)

Integrando precisión probabilística (`WQL_Mean` / `MASE`), cumplimiento del nivel de servicio en inventario (Fill Rate ≥ 90% al mínimo costo total en USD) y costo computacional por cada 1.000 series en Apache Spark, la arquitectura híbrida recomendada para producción en retail de moda es:

Régimen de Demanda	Modelo Primario Recomendado (Con Garantía de Servicio SLA)	Mejor Línea Base Estadística / ML	Justificación Técnica y Operativa Demostrada
Smooth (28,1%)	**ChronosX_Covariates** (o `Moirai_Covariates`)	**SARIMA** (supera a ARIMA en +20,3%)	Líder absoluto en WAPE (0,2403), MASE (0,4928), WQL (0,1652), Fill Rate (98,92%) y mínimo costo de inventario ($80.285).
Erratic (11,9%)	**ChronosX_Covariates** / **Chronos_LoRA_FineTuned**	**SARIMA** (supera a ARIMA en +12,7%)	Cumplen el SLA de Fill Rate (91,3%–92,0%) con el menor costo logístico ($55.360), mientras que LightGBM cae a 87,15% de Fill Rate.
Intermittent (31,6%)	**Chronos_LoRA_FineTuned** / **ChronosX_Covariates**	**CrostonSBA** y **ARIMA** (mejor que SARIMA)	Alcanzan Fill Rate > 93% ahorrando más de $12.000 USD frente a CrostonSBA, evitando el colapso de stock de LightGBM (83,66%).
Lumpy (18,4%)	**Chronos_LoRA_FineTuned** + Stock Seguridad **CrostonSBA**	**CrostonSBA** y **ARIMA** (menor BIC)	`Chronos_LoRA_FineTuned` logra el mejor MASE (0,7452) y WQL (0,8356) entre los TSFM; combinar su P50 con el P90 de SBA maximiza Fill Rate.
Cold_Start (10,0%)	**ChronosX_Covariates** / **Moirai_Covariates**	**LightGBM_Global** y **ARIMA** (nunca SARIMA)	Logran el menor MASE de todo el estudio (0,8244 y 0,8259) transfiriendo escala y elasticidad promocional sin requerir rezagos largos.